

# kpiESR : des indicateurs clés de performance pour les établissements de l'ESR, des données ouvertes aux représentations graphiques

Pauline Boyer et Julien Gossa, Laboratoire SAGE, Université de Strasbourg, CPESR

2024-07-11

## Enjeu et contexte

De profonds changements sont en cours dans l'enseignement supérieur et la recherche (ESR) en France, en accélération depuis le début du XXI<sup>e</sup> siècle (Musselin (2022)). Plusieurs réformes ont modifié la manière dont les établissements d'enseignement supérieur sont gérés et évalués. La création de l'Agence Nationale de la Recherche (ANR) en 2005 a modifié la manière dont les moyens sont alloués aux établissements, tandis que la Loi libertés et responsabilités des universités (LRU) en 2007 a amorcé un mouvement d'autonomisation des universités, les invitant à développer leur propre politique d'emploi. En 2013, l'Agence d'évaluation de la recherche et de l'enseignement supérieur (AÉRES) a été remplacée par le Haut Conseil de l'évaluation de la recherche et de l'enseignement supérieur (Hcéres), modifiant la manière dont les établissements sont évalués.

L'Initiative d'excellence (IDEX) a également été lancée, sélectionnant onze universités pour un projet de gouvernance différenciant dans le cadre du Plan d'investissement d'avenir (PIA) (Aust, Mazoyer, et Musselin (2018)). De plus, un grand nombre de fusions et de regroupements d'établissements d'enseignement supérieur ont eu lieu, tels que les Pôles de recherche et d'enseignement supérieur (PRES) et les Communautés d'universités et d'établissements (COMUE), et plus récemment les Etablissements publics expérimentaux (EPE).

Ces changements ont entraîné des évolutions structurelles locales, visant la différenciation des établissements de l'ESR. Cela a créé un besoin croissant d'outils de suivi et d'analyse pour comprendre les caractéristiques et les politiques des établissements de l'ESR. Dans le même temps, le ministère de l'ESR puis l'Etat ont développé une politique d'ouverture des données administratives, dans la lignée de la Loi pour une république numérique.

## Problématique de recherche

Un pan important de la recherche sur les politiques publiques de l'ESR repose sur des analyses quantitatives à partir de données institutionnelles. Cependant, les données utilisées sont des données à l'accès régulé par la signature de conventions de recherche, directement auprès de l'organisation fournissant les données (composante, établissement, Ministère, agence) ou via le CASD ou Progedo. Si des travaux utilisent des données administratives scrappées (par exemple (Clément, Couto, et Blanchard (2019), Couto, Bugeja-Bloch, et Frouillou (2021))), à notre connaissance, aucun travail n'exploite les données ouvertes.

Pourtant, le Ministère de l'ESR alimente depuis 2014 une plateforme d'open data de nombreux jeux de données structurés (196 disponibles en juillet 2024). Cette non-utilisation des données ouvertes est d'autant plus étonnante que, dans la communication ministérielle, la provision de données pour la recherche figure parmi les objectifs revendiqués de l'open data. Il semble donc légitime de questionner la pertinence de la réutilisation de données ouvertes pour la recherche.

En effet, leur réutilisation expose les chercheurs à de nombreuses contraintes liées à leurs conditions de production et d'ouverture. Tout d'abord, la structure des jeux de données est déterminée par les usages (Bittner et Garfinkel (1967)) avant tout gestionnaires de ces données, tels que l'allocation de moyens aux universités, tout en étant contrainte par l'impératif de protection de l'anonymat. Par ailleurs, les travaux séminaux de Desrosières nous ont appris que les données ne reflètent pas le monde social mais le « reconfigurent et [le]

transforment » (Desrosières (2008)), la mesure étant précédée d'une étape techno-politique de définition des conventions d'équivalence à appliquer. Enfin, tandis que la Loi pour une République numérique faisant de l'ouverture des données un principe par défaut demeure très vague, un soupçon plane encore sur la transparence réalisée lors de l'ouverture des données, une transparence qualifiée de « stratégiquement opaque » (Ruijter et al. (2020)): il n'est pas dans l'intérêt d'une organisation de rendre accessibles des données permettant de critiquer son action.

Ces obstacles nous renvoient à une question centrale en sociologie (Kitsuse et Cicourel (1963)) : si les données institutionnelles ne sont pas des enregistrements neutres d'actes ou d'effectifs mais le produit de déterminations sociales complexes, dans quelle mesure peut-on les utiliser pour évaluer l'action publique ? Autrement dit, peut-on dépasser la porosité de la double fonction des statistiques, à la fois outils de preuve et outils de gouvernement (Desrosières (2008)) ?

Cette proposition de communication prend le parti de la perspective réformatrice du statactivisme, en acceptant « de se placer dans un cadre préétabli, mais y trouv[er] les marges de liberté suffisantes pour le modifier » (Bruno et al. (2014)).

## Méthodologie

L'approche développée au sein de la Conférence des praticiens de l'ESR (CPESR) consiste à exploiter les données administratives ouvertes par le ministère pour élaborer des indicateurs clés de performances (kpi) à la fois exhaustifs et synthétiques. Ce travail s'inscrit à la croisée des sciences des données, avec l'agrégation et la représentation des informations ; et des sciences de l'action publique, avec la sélection d'un sous-ensemble d'indicateur prioritairement pertinents, et la conception d'indicateurs clés composites.

Notre objectif est de construire des tableaux de bord permettant de percevoir les politiques publiques de l'ESR, en se confrontant à plusieurs objectifs contradictoires :

- lisibilité vs. exhaustivité : la lisibilité demande de limiter au maximum le nombre d'indicateurs, alors que l'exhaustivité invite à les démultiplier ;
- robustesse vs. finesse : agréger les données permet de gommer leurs imperfections, mais réduit la finesse des analyses permises ;
- localité vs. globalité : agréger les données au niveau des établissements permet de percevoir les différenciations locales, mais agréger au niveau national est indispensable pour percevoir les transformations globales ;
- contextualisation vs. compétition : les différenciations locales ne se comprennent qu'avec une contextualisation dans le temps et par rapport aux autres établissements, mais ces comparaisons portent le risque d'une mise en compétition<sup>1</sup>.

Les traitements sont effectués avec R (R Core Team 2013) et les visualisations avec ggplot (Wickham 2016), en respectant les principes fondamentaux établis dans (Wilke 2019) et les procédures de production et publication RMarkdown (Xie, Allaire, et Golemund 2019).

## Principaux résultats

Les données ouvertes sont mises à disposition par le SIES<sup>2</sup>, et nous exploitons pour ces travaux les jeux suivants :

- [fr-esr-statistiques-sur-les-effectifs-d-etudiants-inscrits-par-etablissement](#)
- [fr-esr-personnels-biatss-etablissements-publics](#)
- [fr-esr-enseignants-titulaires-esr-public](#)
- [fr-esr-enseignants-nonpermanents-esr-public](#)

---

<sup>1</sup>On retrouve habituellement cette mise en compétition dans les classements, qui s'appuient toujours sur des indicateurs de performance.

<sup>2</sup><https://www.enseignementsup-recherche.gouv.fr/fr/statistiques-et-analyses-50213>

- [fr-esr-operateurs-indicateurs-financiers](#)
- [fr-esr-principaux-etablissements-enseignement-superieur](#)

Le projet kpiESR<sup>3</sup> assemble les données à trois granularités différentes : MESR, groupes d'établissements, et établissement. Les indicateurs retenus sont de quatre ordres : effectifs étudiants, effectifs BIATSS, effectifs enseignants et données financières.

Ces indicateurs sont déclinés en deux types :

- **Les indicateurs primaires et secondaires** : au plus proche des jeux de données ouvertes, ils présentent les effectifs étudiants et personnels, ainsi que les finances.
- **Les indicateurs clés de performance** : combinaisons des précédents, plus représentatives des missions.
  - **Taux de titularité** : effectifs titulaires / total des effectifs
  - **Taux de SCSP** : subvention pour charge de service public / total des ressources
  - **Taux d'encadrement pédagogique** : nombre d'enseignants titulaires pour 100 étudiants
  - **Taux d'encadrement administratif** : effectifs administratifs / total des effectifs
  - **Ressources par étudiant** : total des ressources / effectifs étudiant en Licence et Master
  - **Recettes formation par étudiant** : total des recettes formation (droits d'inscription, alternance, VAE, etc.) / effectifs étudiants
  - **Recette recherche par EC** : total des recettes recherche (ANR, contrat, IDEX) / effectifs enseignant-chercheur

Trois représentations sont ensuite utilisées :

- **Valeurs absolues** : permettant de connaître les valeurs à la dernière année ;
- **Evolutions normalisées** : permettant de percevoir l'évolution dans le temps, en valeur 100 pour une année de référence ;
- **Valeurs normalisées** : permettant connaître un rapport et de le comparer aux autres établissements.

Ces représentations permettent de produire des tableaux de bord pour tous les établissements, avec des informations contextualisées dans le temps et dans l'espace ESR. Ces tableaux de bord sont réunis dans un document unique<sup>4</sup> mais aussi accessibles par une interface web interactive<sup>5</sup>.

## Tableaux de bord

Les différentes représentations mises ensemble constituent un tableau de bord en deux volets, d'abord les indicateurs clés de performance, et ensuite les données primaires. Par exemple, voici les tableaux de bord pour l'ensemble du MESR :



---

<sup>3</sup><https://github.com/cpesr/kpiESR>


<sup>4</sup><https://cpesr.fr/tableau-de-bord-esr/>

<sup>5</sup><https://data.cpesr.fr/tdbesr/>


## Indicateurs clés de performance




## Effectifs étudiants




## Effectifs enseignants



## Effectifs BIATSS




## Indicateurs financiers




## Séries temporelles

Les séries temporelles permettent de percevoir des évolutions. Par exemple, voilà la représentation, en valeur 100 pour 2013 et dans le périmètre MESR, des effectifs enseignants et étudiants, ainsi que du taux d'encadrement. Cette représentation est déclinable par établissement.



## Représentations spatiales

Les représentations spatiales permettent de comparer les établissements entre eux, selon tous les indicateurs du projet. C'est un outil qui peut s'avérer utile au *benchmarking*, comme à l'identifier de corrélations. Par exemple, voici les universités en fonction des taux d'encadrement pédagogique et des budgets par étudiant, selon le périmètre d'excellence, en 2020.



## Limites de l'approche et éléments de discussion

Bien qu'étant le projet public le plus avancé en matière d'agrégation des données de l'ESR, kpiESR présente plusieurs limites, d'abord dûes à l'utilisation des données ouvertes :

- disponibilité : les séries temporelles sont courtes (la plus ancienne débute en 2006), varient en fonction du jeu de données, et on généralement 18 mois de retard par rapport à l'année courante ;
- limitation : en partant des données disponibles plutôt que des besoins, on limite le nombre et le type d'indicateurs calculables ;
- qualité : de nombreux établissements présentent des données partielles ou de mauvaises qualité, ainsi que des ruptures de séries à l'occasion des réformes et transformations telles que les regroupements (fusions, COMUEs, EPE).

Le projet est aussi totalement dépendant de la mise à jour régulière des données ouvertes, ce qui peut poser problème si l'État ralentit ou cesse leur publication. Le projet est donc tributaire de ce que l'Etat souhaite et peut montrer, en quantité comme dans la définition de chaque variable.

Mais le projet est également tributaire de ce que les établissements peuvent et souhaitent montrer. Nous avons ainsi identifié plusieurs cas de chantage (Bruno et Didier (2013)), c'est-à-dire de manipulation des indicateurs, ainsi que plusieurs techniques de « transparence stratégiquement opaque », notamment pour les informations financières.

Enfin, le projet pouvant servir au *benchmarking*, se pose la question de la mise en compétition des établissements, qui se matérialise notamment par la possibilité de fabriquer des classements. Cela interroge directement les choix de définition des indicateurs, qui peuvent tous être retournés. Par exemple, le budget par étudiant reflète l'investissement de l'État, quand son inverse, le nombre d'étudiants formés pour un budget donné, reflète la productivité des établissements. Il s'agit donc de choix éminemment techno-politiques, qui conduisent à des classements totalement inversés, à partir des mêmes données.

Si elle est retenue, la communication décrira la définition des indicateurs sélectionnés et les choix qui les sous-tendent, expliquera en détail les représentations graphiques, puis présentera quelques enseignements sur les politiques publiques de l'ESR, ainsi que des illustrations concrètes des limites de l'approche.

## Références

- Aust, Jérôme, Harold Mazoyer, et Christine Musselin. 2018. « Se mettre à l'IDEX ou être mis à l'index: Conformations, appropriations et résistances aux instruments d'action publique dans trois sites d'enseignement supérieur ». *Gouvernement et action publique* 4 (4): 9. <https://doi.org/ggqsfw>.
- Bittner, E, et H Garfinkel. 1967. « "Good" Organizational Reasons for "Bad" Clinical Records ». In *Studies in Ethnomethodology*. Englewood Cliffs: Prentice Hall.
- Bruno, Isabelle, et Emmanuel Didier. 2013. *Benchmarking: l'État sous pression statistique*. Paris: Zones.
- Bruno, Isabelle, Emmanuel Didier, Julien Prévieux, et Cyprien Tasset. 2014. « Introduction. Pour Un Statactivisme ! » In *Statactivisme*, édité par Isabelle Bruno, Emmanuel Didier, et Julien Prévieux, 5-30. Zones. Paris: La Découverte.
- Clément, Pierre, Marie-Paule Couto, et Marianne Blanchard. 2019. « Parcoursup : infox et premières conséquences de la réforme ». *La Pensée* 399 (3): 144-56. <https://doi.org/10.3917/lp.399.0144>.
- Couto, Marie-Paule, Fanny Bugeja-Bloch, et Leïla Frouillou. 2021. « Parcoursup : les prémices d'un accroissement de la stratification sociale et scolaire des formations du supérieur ». *Agora débats/jeunesses* 89 (3): 23-38.
- Desrosières, Alain. 2008. *Pour une sociologie historique de la quantification : L'Argument statistique I*. Sciences sociales. Paris: Presses des Mines.
- Kitsuse, John I., et Aaron V. Cicourel. 1963. « A Note on the Uses of Official Statistics ». *Social Problems* 11 (2): 131-39. <https://doi.org/10.2307/799220>.
- Musselin, Christine. 2022. *La longue marche des universités françaises*. Paris: Sciences po, les presses.
- R Core Team. 2013. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.

- Ruijter, Erna, Françoise Détienné, Michael Baker, Jonathan Groff, et Albert J. Meijer. 2020. « The Politics of Open Government Data: Understanding Organizational Responses to Pressure for More Transparency ». *The American Review of Public Administration* 50 (3): 260-74. <https://doi.org/10.1177/0275074019888065>.
- Wickham, Hadley. 2016. *Ggplot2: Elegant Graphics for Data Analysis*. 2nd ed. 2016. Use R! Cham: Springer International Publishing : Imprint: Springer. <https://doi.org/10.1007/978-3-319-24277-4>.
- Wilke, C. 2019. *Fundamentals of Data Visualization: A Primer on Making Informative and Compelling Figures*. First edition. Sebastopol, CA: O'Reilly Media.
- Xie, Yihui, Joseph J. Allaire, et Garrett Golemund. 2019. *R Markdown: The Definitive Guide*. Chapman & Hall/CRC, the R Series. Boca Raton London New York: CRC Press, Taylor & Francis Group.